

Representación del Conocimiento

Dos Casos Prácticos: Modelos y Enfoques de Bases de Conocimiento

1. Introducción

La representación del conocimiento (RC) es una rama central de la inteligencia artificial que estudia cómo codificar información sobre el mundo de manera que un sistema computacional pueda utilizarla para razonar, inferir y resolver problemas complejos como el diagnóstico médico, la respuesta a preguntas en lenguaje natural o la recomendación de productos.

A lo largo de la historia de la IA se han desarrollado distintos enfoques para representar conocimiento: lógica de predicados, reglas de producción, redes semánticas, marcos (frames), ontologías y, más recientemente, grafos de conocimiento. Cada uno responde a necesidades diferentes y se apoya en estructuras formales específicas.

El presente documento analiza dos casos prácticos representativos que ilustran cómo se ha aplicado la representación del conocimiento en escenarios reales: el sistema experto MYCIN (enfoque clásico simbólico, basado en reglas) y el Knowledge Graph de Google (enfoque moderno semántico, basado en ontologías y grafos). Ambos comparten el mismo problema fundamental —cómo estructurar el conocimiento para que una máquina lo use— pero lo abordan desde paradigmas distintos y separados por casi cuarenta años de evolución tecnológica.

2. Marco Conceptual

2.1 ¿Qué es una base de conocimiento?

Una base de conocimiento (BC) es un repositorio estructurado donde se almacena información de un dominio específico, junto con las reglas o relaciones que permiten a un sistema realizar inferencias. A diferencia de una base de datos tradicional, la BC no solo guarda hechos, sino también el conocimiento procedimental y declarativo necesario para razonar sobre ellos.

2.2 Principales modelos de representación

- **Lógica formal:** utiliza lógica proposicional y de predicados para expresar hechos y reglas con precisión matemática.
- **Reglas de producción:** estructuras del tipo SI... ENTONCES... que codifican conocimiento heurístico (ej. sistemas expertos).

- **Redes semánticas:** grafos donde los nodos son conceptos y las aristas relaciones entre ellos.
- **Marcos (frames):** estructuras orientadas a objetos que agrupan atributos (slots) y valores de un concepto.
- **Ontologías:** modelos formales que definen clases, propiedades y relaciones de un dominio, base de la web semántica.
- **Grafos de conocimiento:** redes a gran escala que combinan ontologías con datos masivos sobre entidades del mundo real.

3. Caso Práctico 1: Sistema Experto MYCIN

3.1 Contexto y descripción

MYCIN es uno de los sistemas expertos más emblemáticos de la historia de la inteligencia artificial. Fue desarrollado a comienzos de la década de 1970 en la Universidad de Stanford por Edward Shortliffe y sus colaboradores, escrito en LISP, e inspirado parcialmente en DENDRAL, un sistema experto previo orientado a la química. Su propósito principal era asistir a los médicos en el diagnóstico de enfermedades infecciosas de la sangre (especialmente meningitis e infecciones bacterianas graves) y recomendar el tratamiento antibiótico apropiado, incluyendo dosis personalizadas según el peso y características del paciente.

Aunque MYCIN nunca llegó a usarse clínicamente —principalmente por razones éticas y legales relativas a la responsabilidad médica—, demostró por primera vez que un programa podía igualar el desempeño de un especialista humano en un dominio acotado, lo que marcó un hito en la ingeniería del conocimiento y sentó las bases de toda la industria posterior de sistemas expertos.

3.2 Modelo de representación del conocimiento

MYCIN utiliza un enfoque simbólico basado en reglas de producción. Su base de conocimiento estaba formada por aproximadamente 500 reglas codificadas manualmente por expertos en enfermedades infecciosas. Cada hecho en la base se representa como una tripleta asociativa del tipo (objeto, atributo, valor), acompañada de un Factor de Certeza (FC) que indica el grado de confianza en dicho hecho dentro de una escala de -1.0 a $+1.0$.

Estructura de una regla típica

```
SI:   - sitio del cultivo = sangre   - tinción Gram = positivo   - morfología
      = cocos en cadena ENTONCES:  - organismo probable = Streptococcus   - factor
      de certeza = +0.7
```

Este formato modular permite que cada regla sea pequeña, revisable e interpretable de manera independiente. Un especialista podía inspeccionarla, discutirla, corregirla o extenderla sin necesidad de rehacer el sistema completo.

3.3 Arquitectura del sistema

MYCIN presenta una arquitectura clásica de sistema experto, con una separación estricta entre conocimiento y procesamiento. Sus componentes principales son:

Componente	Función
Base de conocimiento	Almacena las ~500 reglas SI-ENTONCES y los hechos clínicos sobre microorganismos, antibióticos y dosis.
Motor de inferencia	Aplica encadenamiento hacia atrás (backward chaining) para descartar diagnósticos hasta llegar al más probable.
Memoria de trabajo	Conserva los datos del paciente y los hechos derivados durante la consulta en curso.
Interfaz de usuario	Realiza preguntas al médico (síntomas, edad, resultados de laboratorio) y muestra el diagnóstico.
Componente explicativo	Permite al médico solicitar la justificación del razonamiento mediante preguntas tipo "¿por qué?" y "¿cómo?".

3.4 Flujo de funcionamiento

Cuando un médico consulta MYCIN, el sistema sigue un proceso estructurado de razonamiento:

1. Recolección de datos generales del paciente (nombre, edad, síntomas).
2. Planteamiento de hipótesis sobre posibles diagnósticos.
3. Verificación mediante encadenamiento hacia atrás: el sistema busca si las premisas de cada regla se cumplen, formulando nuevas preguntas si es necesario.
4. Cálculo de los factores de certeza acumulados a partir de la evidencia disponible.
5. Emisión del diagnóstico más probable y recomendación terapéutica (antibiótico, dosis, duración).

3.5 Manejo de la incertidumbre: factores de certeza

Una de las contribuciones más originales de MYCIN fue el modelo de factores de certeza (CF), diseñado para tratar la incertidumbre típica de la medicina (síntomas ambiguos, evidencia parcial) sin sacrificar la modularidad de las reglas. Para una hipótesis H y una evidencia E , el factor de certeza se define como:

$$CF(H, E) = MB(H, E) - MD(H, E) \quad \text{donde:} \quad MB(H, E) = \text{medida del incremento de creencia en } H \text{ dada } E$$

$$MD(H, E) = \text{medida del incremento de incredulidad en } H \text{ dada } E$$

Este modelo permitió a MYCIN combinar evidencia parcial procedente de varias reglas y producir conclusiones graduales en lugar de respuestas binarias, anticipándose conceptualmente a los enfoques probabilísticos posteriores.

3.6 Fortalezas y limitaciones

Fortalezas	Limitaciones
Modularidad: cada regla es independiente y puede revisarse aisladamente.	Adquisición del conocimiento costosa: requiere entrevistas extensas con expertos.
Capacidad explicativa: justifica cada diagnóstico paso a paso.	Escalabilidad limitada: añadir reglas puede generar conflictos e inconsistencias.
Manejo de incertidumbre mediante factores de certeza.	Dominio muy estrecho: no aprende de nuevos casos automáticamente.
Desempeño comparable al de un especialista humano en su dominio.	Nunca se desplegó en clínica por motivos éticos y de responsabilidad.

4. Caso Práctico 2: Google Knowledge Graph

4.1 Contexto y descripción

El Knowledge Graph (Grafo de Conocimiento) de Google fue presentado oficialmente en 2012 como una evolución radical del motor de búsqueda. Su objetivo, según Google, era pasar de buscar "cadenas de caracteres" a buscar "cosas": comprender el significado de las entidades del mundo real (personas, lugares, libros, organizaciones, eventos, conceptos) y las relaciones que existen entre ellas, en lugar de limitarse a comparar palabras clave.

Hoy en día, el Knowledge Graph contiene más de 500 mil millones de hechos sobre más de 5 mil millones de entidades. Es la base que alimenta los paneles de información que aparecen a la derecha de los resultados de búsqueda, las respuestas directas, los carruseles de personajes relacionados y muchas funciones de Google Assistant. Cuando un usuario busca "Marie Curie", por ejemplo, no solo obtiene enlaces, sino también su biografía resumida, sus descubrimientos, fechas clave, fotografías y científicos relacionados.

4.2 Modelo de representación del conocimiento

A diferencia de MYCIN, el Knowledge Graph se basa en un enfoque semántico inspirado en las ontologías y la web semántica. La unidad básica de información es la tripleta semántica, una estructura de la forma (sujeto, predicado, objeto) que codifica un hecho del mundo:

```
(Marie_Curie, nació_en, Varsovia) (Marie_Curie, ganó, Premio_Nobel_de_Física)
(Premio_Nobel_de_Física, año, 1903) (Marie_Curie, casada_con, Pierre_Curie)
```

Estas tripletas, cuando se acumulan a gran escala, forman un grafo dirigido en el que los nodos son entidades y las aristas son relaciones tipadas. Sobre este grafo se aplica una ontología, que define las clases de entidades posibles (Persona, Lugar, Película, Organización...) y las relaciones válidas entre ellas (una Persona puede actuar_en una Película, pero no en una Ciudad).

4.3 Componentes principales

Componente	Descripción
Entidades	Objetos del mundo real o conceptos abstractos identificados con un ID único (ej. Apple la fruta vs. Apple Inc.).
Atributos	Propiedades específicas de cada entidad (ej. París → población: 2.1 millones; país: Francia).
Relaciones	Aristas tipadas que conectan entidades (nació_en, autor_de, fundador_de, dirige...).
Ontología	Esquema que define qué clases existen y qué relaciones son válidas entre ellas.
Motor de inferencia	Razonador semántico que deriva nuevos hechos a partir de los explícitos (ej. transitividad de relaciones).

4.4 Funcionamiento práctico

Cuando un usuario realiza una consulta como "libros de J. R. R. Tolkien", el sistema no busca simplemente las páginas que contienen esas palabras. En lugar de eso:

1. Identifica que "J. R. R. Tolkien" es una entidad de tipo Persona (concretamente, un Autor).
2. Reconoce "libros" como una relación del tipo escribió o autor_de.
3. Recorre el grafo siguiendo las aristas escribió desde el nodo Tolkien.
4. Devuelve las entidades conectadas (El Señor de los Anillos, El Hobbit, El Silmarillion...) junto con sus atributos.
5. Presenta la información en un panel estructurado, con datos relacionados y enlaces a entidades vecinas en el grafo.

4.5 Otros casos de aplicación

El paradigma de los grafos de conocimiento se ha extendido más allá de Google. Algunos ejemplos representativos del sector:

- **DBpedia:** estructura el contenido de Wikipedia en formato de grafo, con más de 100 millones de hechos, y es una pieza central del movimiento Linked Open Data.
- **eBay:** utiliza un grafo de conocimiento para mejorar las recomendaciones en tiempo real, combinando comportamiento del usuario, historial de compras y características de los productos.
- **Airbnb:** emplea grafos de conocimiento para responder preguntas de viajeros sobre destinos, conectando ciudades, eventos, monumentos y puntos de interés.
- **LinkedIn y Facebook:** modelan redes profesionales y sociales como grafos de personas, empresas, habilidades y publicaciones interconectadas.

4.6 Fortalezas y limitaciones

Fortalezas	Limitaciones
Escala masiva: miles de millones de entidades y relaciones.	Calidad de los datos: depende de fuentes heterogéneas que pueden contener errores.
Interoperabilidad: estándares abiertos (RDF, OWL, SPARQL) permiten conectar grafos.	Ambigüedad: distinguir entidades homónimas requiere desambiguación contextual.
Dominios múltiples: cubre cualquier tema sin diseño específico.	Mantenimiento: actualizar relaciones a gran escala es costoso.
Inferencia automática: los razonadores derivan hechos nuevos sin codificación manual.	Cobertura desigual: entidades populares están bien descritas; las raras, no.

5. Análisis Comparativo de los Dos Casos

Ambos sistemas ilustran cómo la representación del conocimiento ha evolucionado desde un paradigma simbólico cerrado y artesanal hacia uno semántico, distribuido y a gran escala. La siguiente tabla resume las diferencias clave:

Criterio	MYCIN (1972)	Google Knowledge Graph (2012)
Modelo de RC	Reglas de producción SI-ENTONCES	Tripletas semánticas + ontología
Dominio	Específico (infecciones bacterianas)	General (todo el conocimiento humano)

Criterio	MYCIN (1972)	Google Knowledge Graph (2012)
Escala	≈ 500 reglas codificadas a mano	> 5.000 millones de entidades
Adquisición	Manual, vía entrevistas a expertos	Automática, vía scraping y fuentes abiertas
Inferencia	Encadenamiento hacia atrás + factores de certeza	Razonamiento ontológico + recorrido del grafo
Incertidumbre	Factores de certeza (−1 a +1)	Probabilidades, scores de confianza por fuente
Explicabilidad	Alta: muestra la cadena de reglas aplicadas	Media: muestra entidades y enlaces, no la inferencia interna
Aprendizaje	Inexistente: el sistema no se adapta	Continuo: incorpora nuevas entidades constantemente
Paradigma	Simbólico clásico (GOF AI)	Semántico + estadístico moderno

6. Conclusiones

El estudio comparado de MYCIN y Google Knowledge Graph muestra dos formas profundamente distintas de responder a una misma pregunta: cómo representar el conocimiento para que una máquina razone con él. MYCIN encarna la apuesta clásica de la IA simbólica: capturar manualmente la experiencia humana en reglas explícitas, pequeñas, modulares y revisables. Su gran fortaleza —la transparencia y la capacidad de explicar cada decisión— es también su mayor cuello de botella, porque el costo de mantener y ampliar la base de conocimiento crece linealmente con la complejidad del dominio.

Por su parte, el Knowledge Graph de Google representa la madurez del enfoque semántico moderno: en lugar de codificar reglas, se construye un grafo masivo de entidades y relaciones que se alimenta de fuentes diversas y se enriquece de forma continua. Su poder reside en la escala y la interoperabilidad, pero a costa de cierta opacidad y una dependencia fuerte de la calidad de los datos.

Ninguno de los dos enfoques es absoluto: muchas aplicaciones modernas combinan ambos paradigmas. Los grafos de conocimiento se utilizan, por ejemplo, junto con modelos de lenguaje grandes (LLMs) para anclar las respuestas en hechos verificables (técnicas como Retrieval-Augmented Generation), mientras que los sistemas expertos siguen vigentes en dominios críticos donde la trazabilidad del razonamiento es indispensable, como la medicina, el derecho o el cumplimiento normativo.

En definitiva, la representación del conocimiento sigue siendo un campo central de la inteligencia artificial: del simple SI-ENTONCES de MYCIN al grafo planetario de Google, lo que persiste es la idea fundamental de que para razonar bien hay que estructurar bien lo que se sabe.

7. Referencias

- Shortliffe, E. H. (1976). *Computer-Based Medical Consultations: MYCIN*. Elsevier. Stanford University.
- Buchanan, B. G., & Shortliffe, E. H. (1984). *Rule-Based Expert Systems: The MYCIN Experiments of the Stanford Heuristic Programming Project*. Addison-Wesley.
- Russell, S. J., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
- Singhal, A. (2012). *Introducing the Knowledge Graph: things, not strings*. Google Official Blog.
- Hogan, A. et al. (2021). *Knowledge Graphs*. *ACM Computing Surveys*, 54(4), 1–37.
- Wikipedia: artículos sobre Mycin y Grafo de conocimiento (consultados en 2026).
- IBM (2025). *What is a Knowledge Graph?* IBM Think Topics.